


贺鑫帅

- 先是借助国产深度学习框架平台paddlepaddle的在线学习文档《零基础实践学习深度学习》进行了深度学习相关基础、cv的基本入门以及飞桨框架的基本学习。
- 后来又选择性阅读了Github上爆火的书籍《深度学习500问》,进一步恶补基础。
- 接着为了了解目前该项目cv相关的情况,通过知乎以及google scholar 阅读了相关解读文章和论文。
 1. cnn相关架构的发展
 2. 针对该项目的cv相关的实现方案进行了总结。
 3. 对深度多模态学习相关知识进行了了解



○ 阅读的论文如下

- Research on Video Abnormal Behavior Detection Based on Deep Learning
- Campus violence action recognition based on lightweight graph convolution network
- Not only Look, But Also Listen: Learning Multimodal Violence Detection Under Weak Supervision
- Violence Detection in Videos Based on Fusing Visual and Audio Information
- Spatio-Temporal AutoEncoder for Video Anomaly Detection

- 基于YOLOv8的暴力行为检测系统
- 技术论文|基于人体关节点多特征融合的暴力行为识别

- 浅谈动作识别TSN, TRN, ECO
- 【论文分享】TSM: 实现高效率视频理解的时序移动方法
- 时空建模新文解读: 用于高效视频理解的TSM
- 【论文分享】TSM: 实现高效率视频理解的时序移动方法
- 更快更强! 视频理解模型PP-TSM重磅发布: 速度比SlowFast快4.5倍
- 人人都能看懂的LSTM
- 从入门到放弃: 深度学习中的模型蒸馏技术
- 模型压缩-剪枝算法详解
- 模型压缩-量化, 剪枝, 蒸馏, 二值化

○ 视频分类

- 传统cv 手工提取+分类器
- 基于深度学习

■ 2d

1. 基于cnn

- two stream CNN

通过两个2维卷积层分别提取spacial和temporal的特征

- tsn

在two stream CNN的基础上引入稀疏时间采样思想,减少了计算量.

- trn

1. 对时间帧进行组合.
2. 融合函数更加复杂而非简单平均池化.

- eco

在稀疏时间采样后,使用C3D而非简单2d来提取时空特征

- tsm

人为调度temporal channel来近似模拟卷积,从而使2d的计算量达到3d的效果.

2. 基于rnn

- LSTM

引入门控来抽象实现忘记、记忆等作用

- 结论方案(**PPTSM**)

- 经过对比TSM具有2维的运算速度,同时有接近3维的性能.而PP上刚好有PPTSM,虽然百度在AI上起了个大早,赶了个晚集,但是国产自研框架还是意义非凡,于是还是尝试使用PaddlePaddle这个平台.

更快更强! 视频理解模型PP-TSM重磅发布: 速度比SlowFast快4.5倍

- 研究方向

1. transformer在视频的应用

- Timesformer
- Video Swin Transformer

- [【论文分享】视频理解中的时空注意力机制\(TimeSformer\)](#)

2. 重构判别

校园暴力的样本要远远小于正常样本的数量,重构判别对于该项目正负样本严重不均衡的情况或许有奇效.

3. VLM-R1

这个项目参考来自去年 DeepSeek 开源的 R1 模型的GRPO (Group Relative Policy Optimization) 强化学习方法(在纯文本大模型上取得了惊人的效果),将其应用到视觉理解上,比较有意思.

4. 模型压缩

出于对算力成本以及暴力检测时效性的考虑,后期想实际落地这个项目的话,可能需要通过模型蒸馏等技术来对比较好的性能模型进行压缩.

3. 多模态深度学习的方案

○ 阅读论文及文章如下

- [Multimodal fusion methods with deep neural networks and meta-information for aggression detection in surveillance meta- information](#)
- [Multimodal Attention Network for Violence Detection](#)
- [多模态深度学习：用深度学习的方式融合各种信息](#)
- [解读论文-Dynamic Multimodal Fusion, CVPR, 2023](#)
- [混合专家模型 \(MoE\) 详解](#)

○ 初步想法

选取情感、视频、音频、(文本)模态进行分析,形成感性与理性分析结合的架构.

架构如下

- 模态数据选择：模态级DynMM（基于MOE）根据当前情况（光照、噪声（如雨声）等）选择合适输入模态数据。
- 分析部分
 - "理性分析"：构建端到端的大多模态深度学习网络，直接基于原始的视频、音频、文本数据进行建模，形成理性分析。
 - "感性分析"：通过传统特征提取进而构建情感分析的深度学习网络，形成感性分析。
- late fusion：最后通过一个fusion模块，对分析的结果进行融合。

4. 今后方向

1. 先基于现有已落地的SOTA模型(PP_TSM等)实现比对一下,在4-5月份评定立项等级之前先大体形成一个可用的demo.
2. 进一步探索和实验前沿论文中提到的可参考移植的模型,来进一步优化我的模型,(如上述研究方向的探究transformer在视频应用、尝试实现基于重构判别的实现方法、考虑优化那些计算量大但性能好的模型,随后用蒸馏等压缩模型望得到更好的解决方案)