

工作总结

一、综述

首先，我进行了与音频模式识别以及文本分析相关的机器学习的知识的了解与学习。较主要的是：

- 卷积神经网络 (CNN)
- 长短期记忆人工神经网络 (LSTM)
- Transformer
- 迁移学习
- 微调
- 预训练
- 自然语言处理 (NLP)

在有了大致的一个了解下，我开始着手于文章的阅读和学习，了解相关技术的发展现状，来大致确定使用什么模型、如何优化与创新。

- **IEEEXplore**：我将近五年与“校园暴力检测”相关的文章都进行了浏览，经过现有研究结果各模型的比对，我对音频处理方面要用到的模型与算法有了一个方向——**PANNs**。

[Violent Video Recognition Based on Global-Local Visual and Audio Contrastive Learning](#)

[Detection of Violent Content in Videos using Audio Visual Features](#)

[Violence Detection in Videos Based on Fusing Visual and Audio Information](#)

- **ACMDigitalLibrary**：在ACMDL上我主要了解了文本分析的现状。
- **GoogleScholar**：通过谷歌学术我搜索到了IEEE数字图书馆以及ACM数字图书馆的好渠道，也有其他平台上的文章。我大致确定了在文本分析方面性能较优秀的模型——**RoBERTa-wwm-ext**。了解了国内以及国外一些学者在相关方面的研究后，让我在此基础上有了一些创新的想法。
- **微信公众号**：“深夜努力写python”博主的文章可以让我对相关模型、方法等有个快速的了解。
- **CSDN**：CSDN上有博主分享我拟使用的模型PANN的具体应用，我可以进行参考；由于我查找的几乎是英文文章，要详细了解PANNs，仅靠机翻会造成一些理解上的误差，CSDN上有博主对这篇论文加以自己的理解与总结。

[论文解读《PANNs: Large-Scale Pretrained Audio Neural Networks for Audio Pattern Recognition》](#)

[用python实现基于PANN \(retrained Audio Neural Networks\) 的声音检测方法](#)

二、实施方案

1. 音频

1. 拟选择使用模型——PANNs中的CNN14

- PANNs是基于大规模AudioSet数据集训练的**预训练音频神经网络**，也可以转移到其他与音频相关的任务中。PANNs中的Wavegram-Logmel-CNN架构的mAP达到0.439，优于之前最好的系统0.392；将PANNs转到六个音频模式识别任务中，在其中几个任务中展示了最先进的性能。
- PANNs在训练时就使用Mixup和SpecAugment进行数据增强。

[PANNs: Large-Scale Pretrained Audio Neural Networks for Audio Pattern Recognition](#)

- 通过查阅资料我发现，相关研究使用的大多是传统的特征提取方法（人工提取MFCC再结合神经网络或向量机进行分类/VGGish），平均识别率并不是很高；还有的是用CNN与LSTM相融合，但融合不当就会使模型性能降低；transformer有长时间依赖性，而暴力事件不会像transformer需要的那么长时间，在音频方面相比于CNN14还是不够适合。

[Automated multi-modal recognition of school violence](#)

[Campus bullying detection based on motion recognition and speech emotion recognition](#)

[Campus Violence Detection Based on Artificial Intelligent Interpretation of Surveillance Video Sequences](#)

- 而PANNs是专门为了音频设计的大规模数据集上预训练的神经网络，准确度很高，且非常适合于音频分类。虽然它是一个提出不久的模型，但已有不少研究使用并证明**PANNs音频提取特征能力比VGGish强**。

[Multimodal Attention Network for Violence Detection](#)

[VI-PANN: Harnessing Transfer Learning and Uncertainty-Aware Variational Inference for Improved Generalization in Audio Pattern Recognition](#)

- **创新想法：**

使用PANNs的创新：现有研究几乎对非语音暴力声学特征没有很关心，但使用PANNs可以兼顾语音和非语音特征，为视频提供更好的辅助。

CNN14与Wavegram-Logmel-CNN对比实验：PANNs中有一个比CNN14准确度更高的模型Wavegram-Logmel-CNN,但它处理环境音和较为复杂且包含微妙的瞬时特征更好，计算量和复杂度更高，我需要确定哪个更适合处理训练的数据集。


CNN14与Wavegram-Logmel-CNN特征级融合：由上一点得到启发。

微调CNN14使其处理瞬时特征的性能增强：由上一点得到启发。

微表情语音：检测强行压抑情绪的声带颤动（通过高频谐波分析）。

- **评估：**五折交叉

2. 以下是我画的大致流程：



2. 文本

文本可以辅助音视频检测暴力事件。

1. 拟选择使用模型——RoBERTa-wwm-ext

- RoBERTa-wwm-ext 是通过全词掩蔽预训练方法针对中文字符属性设计的，对于中文这种没有空格分隔的语言来说是非常有用的，大大提高了模型识别中文实体的能力。

[Chinese Named Entity Recognition for IC Patent Domain Based on RoBERTa-wwm-ext, GCN and Efficient Global Pointer](#)

[MSEVA : A System for Multimodal Short Videos Emotion Visual Analysis](#)

[RoBERTa: A Robustly Optimized BERT Pretraining Approach](#)

[RoBERTa-based Video-Associated Text Feature Explainable Performance Prediction](#)

2. 创新想法

创新点	适用性
知识图谱 + 暴力语义匹配	识别隐晦暴力言论
RoBERTa 轻量化（量化、蒸馏）	部署友好，适合低算力设备
GNN 进行文本关联分析	识别群体暴力与欺凌

与GNN的结合或许在文本分类方面会得到效果的提升

[BGNN-TC: 基于 BERT GNN 的文本分类算法](#)

[基于GNN的文本分类](#)

3. 融合

在最先开始查找资料时，我对相关的内容做了一份笔记，涉及到融合方面的一些方法和思考。

[笔记.md](#)

融合策略

- 决策级融合
- 特征级融合
 - e.g.在改进的 D-S 融合算法中，引入互信息最大化和对比学习模块促进音频和视频模态的不变性
[A Robust Framework Based on Mutual Information and Contrastive Learning for Multimodal Violence Detection in Videos](#)
 - 语音-动作降维方法：PCA、LDA（适用性？）
 - 校园欺凌是青少年中常见的社会问题，其表现形式多种多样，其中身体暴力被认为是最具危害性的。但现有的校园暴力举报方式均为人工驱动，受害者使用起来十分不便。因此，作者的研究小组旨在开发自动暴力识别方法。

首先，本文提出了一种模糊多阈值算法。然而，随着涉及不同年龄和性别的玩家的活动越来越多，它的表现就不再那么有效了。因此提出了比例 K 最近邻算法来解决这个问题，实现了 80% 的平均识别准确率。

然后加入语音情感识别。提取时域和频域运动特征用于活动识别，提取梅尔频率倒谱系数用于情绪识别。使用反向传播神经网络作为分类器，平均准确率达到 87.8%。

为了进一步提高识别性能，使用了额外的运动传感器。从每个传感器分别提取运动特征。提出了一种改进的Relief-F算法来选择有用的、低冗余的运动特征，同时采用径向基函数神经网络作为分类器。提出了一种改进的 Dempster-Shafer 融合算法，将各个传感器的分类结果结合起来。平均识别准确率达到 93.6%。

为了解决欺凌者摘除可穿戴传感器的问题，提出了一种基于图像的暴力识别方法。监控摄像机捕获图像，并利用目标检测算法和形态学处理方法检测前景目标。提出了一种外接矩形框架（CRF）集成方法来细化检测到的目标。提取了CRF特征和光流特征，并采用了三种不同的选择方法来选取有用的特征。设计了决策树-支持向量机分类器，平均识别准确率达到97.6%。

综上所述，本论文提出了两种主要的校园暴力识别方法：基于运动传感器的；以及基于监控摄像头的。两种方法都表现出了令人满意的识别结果，表明了自动检测校园暴力事件的潜力。

模态组合场景

四种样本组合：

- 暴力视频 + 欺凌音频 → 标记为暴力（标记为正面）
- 暴力视频 + 非欺凌音频 → 玩耍或竞技游戏（标记为负面）
- 非暴力视频 + 欺凌音频 → 批评场景（标记为负面）
- 非暴力视频 + 非欺凌音频 → 日常生活（标记为负面）

最终根据组合判断暴力风险